





Description du challenge :

https://www.kaggle.com/c/talkingdata-adtracking-fraud-detection



En résumé :

Sur un site WEB qui collecte des données d'activité sur les "clics" :

détecter/prédire qui a vraiment utilisé l'application mobile proposée (en la téléchargeant) pour ne pas prendre en compte ceux qui auraient juste cliqué (robots ou actions malveillantes)



Le challenge Kaggle 2/2

Les données collectées :

- **ip**: ip address of click.
- app: app id for marketing.
- **device**: device **type** id of user mobile phone (e.g., iphone 6 plus, iphone 7, huawei mate 7, etc...)
- os: os version id of user mobile phone
- · channel: channel id of mobile ad publisher
- click_time: timestamp of click (UTC)
- attributed_time: if user download the app for after clicking an ad, this is the time of the app download

Données à prédire :

 is_attributed: the target that is to be predicted, indicating the app was downloaded





Méthodologie

Utilisation de Watson Studio (DataScience eXperience):

- https://datascience.ibm.com
- Projet : « TechData DATA DEALER »

Chargement des données extraites de Kaggle :

- Jeu d'entrainement : train_sample.csv 100 000 lignes de données aléatoires
- Jeu de test : test.csv 18 M rows

Exploration et raffinage des données :

- Préparation des données : Data Refinery
- Création de nouvelles colonnes (feature engineering)
- Création de rapports statistiques sur les données
- Ecriture d'un Notebook Jupyter/Python : AdTracking Data exploration

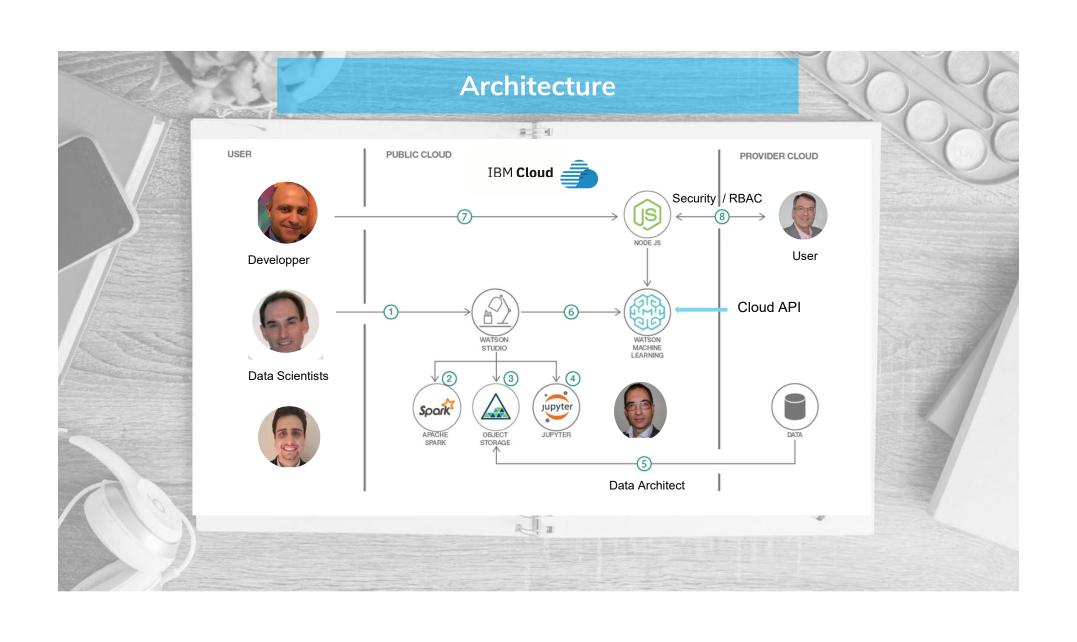
Modélisation:

- Ecriture d'un Notebook Jupyter/Python : AdTracking Data Modeling
- Choix de l'algorithme de modélisation : xgboost
- Mesure des indicateurs

Exploitation:

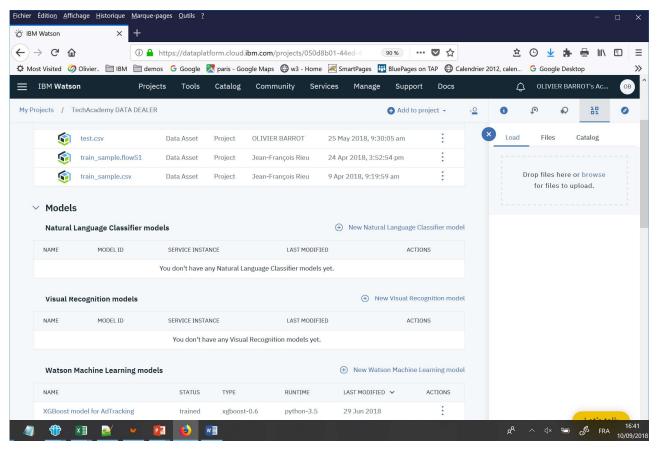
- Publication du modèle via Watson ML
- Création d'un client test qui se connecte via API REST





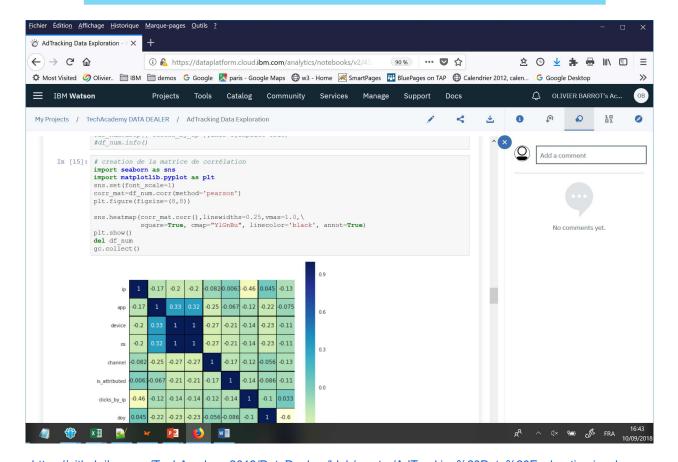


Environnement Watson Data Studio



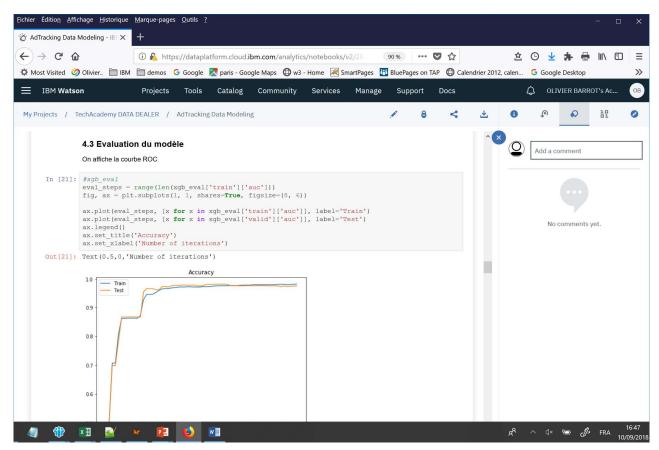
https://www.ibm.com/cloud/watson-studio

Notebook exploration



https://github.ibm.com/TechAcademy2018/DataDealers/blob/master/AdTracking%20Data%20Exploration.ipynb

Notebook modélisation



https://github.ibm.com/TechAcademy2018/DataDealers/blob/master/AdTracking%20Data%20Modeling.ipynb

Client Node.js / WatsonML

